

Informe Final — Proyecto Integrador: Minería de Datos I

Integrantes: Nicolás Daniel Segovia Albarado y Joaquin Corvalan Celiz

Comisión: Turno Tarde — Sede Nodo Tecnológico

Fecha: 08 de Julio 2026

1. Contexto y objetivo

El proyecto analiza el comportamiento de usuarios de una plataforma de streaming latinoamericana. El objetivo fue construir un pipeline reproducible de análisis de datos que incluya inspección, limpieza, análisis exploratorio y reducción de dimensionalidad, con decisiones justificadas y trazabilidad completa del proceso.

2. Dataset y calidad inicial

El dataset original contenía 8.160 registros en formato JSON con 8 variables: identificador de usuario, edad, plan de suscripción, minutos de consumo mensual, país, género favorito, fecha de último login y tickets de soporte. Se detectaron 126 filas duplicadas exactas, 34 `user_id` con más de un registro, 15 variantes en `subscription_plan`, 26 en `country` y 29 en `favorite_genre`. Además se encontraron valores negativos en variables numéricas, outliers extremos y fechas inválidas en `last_login_date`.

3. Decisiones de limpieza y preparación

Se eliminaron los 126 duplicados exactos y se resolvieron los 34 `user_id` duplicados conservando el último registro. Las variantes de las columnas categóricas se unificaron mediante diccionarios de mapeo. Los valores negativos en `customer_support_tickets` y `monthly_watch_time_mins` se convirtieron a positivos usando valor absoluto. Los outliers extremos se imputaron con 0. Las edades fuera del rango 18-100 se imputaron con la mediana (35 años). Se realizó análisis MCAR/MAR/MNAR, identificando que los nulos en `monthly_watch_time_mins` son MAR (dependen del plan Premium) y se imputaron por grupo. Los nulos en `favorite_genre` se reemplazaron con 'Desconocido' y en `last_login_date` con la fecha mediana (2022-02-15). El dataset final contiene 8.000 filas y 8 columnas sin valores nulos, con una retención del 98.04% de los registros originales.

4. Hallazgos del análisis exploratorio

El usuario típico tiene 35 años, consume alrededor de 750 minutos mensuales y abre entre 0 y 1 tickets de soporte. La distribución por país es equilibrada entre los 7 mercados. El plan Básico concentra el 45% de los usuarios en todos los países. La matriz de correlación mostró que las variables numéricas son prácticamente independientes entre sí, con correlaciones menores a 0.02. Consumir más contenido no implica abrir más tickets de soporte, y la preferencia de género no varía significativamente según la edad o el plan de suscripción.

5. PCA

Se aplicó One-Hot Encoding sobre las variables categóricas y StandardScaler antes del PCA. Se necesitan 13 componentes para explicar el 80% de la varianza y 14 para el 90%, lo que refleja la baja correlación entre variables. PC1 captura la dimensión de plan y consumo (`subscription_plan_Premium`, `subscription_plan_Estándar`, `monthly_watch_time_mins`). PC2 captura preferencias de contenido y origen geográfico (`favorite_genre_Comedia`, `country_Colombia`, `country_Chile`).

6. Conclusiones y limitaciones

El análisis no encontró correlaciones significativas entre las variables del dataset. El plan elegido y el consumo no dependen del país ni de la edad. Los tickets de soporte no afectan el consumo mensual. El PCA confirmó la independencia entre variables. Como limitaciones, la imputación aplicada en varias columnas puede haber

suavizado distribuciones reales, y los nulos MAR en monthly_watch_time_mins introducen un sesgo leve. Como próximos pasos se propone aplicar clustering para segmentar usuarios y explorar modelos predictivos de cancelación de suscripción.

Enlaces del proyecto

Repositorio GitHub: https://github.com/Nicolas230493/PI_Mineria_Datos_1.git

Aplicación Streamlit: <https://pimineriadatos1-ws4febtporanq5vkpgkhjn.streamlit.app/>