

INFORME EJECUTIVO: AUDITORÍA Y COMPORTAMIENTO DE USUARIOS

Para: Gerencia de Producto y Dirección Ejecutiva

De: Nicolás Daniel Segovia Albarado & Joaquin Corvalan Celiz

Área: Minería de Datos I

Fecha: Junio 2026

1. Introducción y Objetivos

Este informe resume los hallazgos estratégicos extraídos de la base de usuarios de streaming. El objetivo fue diseñar un pipeline reproducible para auditar la calidad de los datos, evaluar si las fallas técnicas erosionan el consumo de la plataforma y modelar la estructura matemática mediante Análisis de Componentes Principales (PCA) para optimizar futuras segmentaciones.

2. Auditoría de Calidad y Robustez del Pipeline (ETL)

La ingesta cruda original (8,124 registros en JSON) presentaba severas anomalías operativas que ponían en riesgo la toma de decisiones:

- **Duplicados:** 74 registros idénticos que inflaban la muestra de forma artificial.
- **Inconsistencias:** Nombres de planes registrados con nomenclaturas mixtas (`basic`, `B`, `BASIC`).
- **Outliers Extremos:** Edades imposibles (negativas o mayores a 100 años) y tiempos de visualización incoherentes.
- **Deficiencias Temporales:** Fechas de último login vacías, formatos mezclados y registros con fechas futuras.

Para evitar un filtrado destructivo, se aplicó un pipeline de curación estadística controlada. Se removieron los duplicados exactos y se utilizó **imputación por la mediana** para variables continuas, fijando la edad típica en **33 años** y el tiempo de consumo en **756.3 minutos mensuales**. Las etiquetas comerciales se unificaron y las fechas se normalizaron a `datetime64`.

Resultado: La base se estabilizó de forma robusta en **8,000 filas y 8 variables**, reteniendo el 98.47% de la información original sin sesgos.

3. Hallazgos del Análisis Exploratorio (EDA)

El cruce estadístico multivariable arrojó tres certezas de negocio críticas:

- **Equilibrio de Mercado:** La base está perfectamente balanceada entre los 7 países de Latinoamérica analizados. El plan *Básico* lidera la cuota comercial con un 45% de dominancia transversal, seguido equitativamente por *Standard* y *Premium*.
- **Insignificancia de la Fricción Operativa:** Al evaluar los minutos de consumo mensual frente a las quejas en atención al cliente, se detectó un **coeficiente de correlación lineal nulo de -0.01**. La apertura de tickets de soporte no provoca una contracción en el tiempo de visualización del usuario.
- **Ausencia de Nichos Etarios:** Las medianas de edad se estabilizan simétricamente **entre los 30 y 40 años** en todas las combinaciones de géneros cinematográficos favoritos y tipos de suscripción. Se descarta la existencia de tribus etarias aisladas por contenido.

4. Diagnóstico de Reducción Dimensional (PCA)

Se aplicó PCA tras normalizar los datos con `StandardScaler` (Media = 0, Varianza = 1) para evaluar la viabilidad de sintetizar las características del usuario.

El veredicto matemático determinó que **el dataset posee una bajísima correlación lineal interna**. La curva de varianza acumulada (*Scree Plot*) demostró un ascenso pausado, evidenciando que **se requieren 13 componentes independientes para explicar el 80% de la variabilidad total** (y 15 para alcanzar el 90%). Al actuar las variables con absoluta autonomía, los métodos de reducción lineal tradicionales ven limitada su capacidad de compresión.

5. Recomendaciones Estratégicas

1. **Campañas Regionales Unificadas:** Dada la homogeneidad demográfica y comercial, se sugiere desplegar estrategias de marketing masivas a nivel Latinoamérica para optimizar costos de localización.
2. **Evolución del Modelado:** Al probarse que el comportamiento de los usuarios es no-lineal (gracias al PCA), el equipo de datos debe omitir regresiones tradicionales y avanzar hacia **algoritmos de clustering avanzado basados en densidad (DBSCAN)** o modelos de árboles de decisión para el próximo motor de recomendación.